Proyecto final Curso EDA

Tatiana Araya Arce

Informe Técnico: Detección de Fraude en Transacciones Financieras mediante Minería de Datos y Aprendizaje Automático

1. Resumen ejecutivo

El presente proyecto tuvo como objetivo desarrollar un sistema de análisis para la detección de fraude en transacciones financieras utilizando técnicas de minería de datos, aprendizaje no supervisado y aprendizaje supervisado.

Se trabajó con un conjunto de 5.000 transacciones financieras, en el cual la variable objetivo es_fraude presentaba un fuerte desbalance de clases, con aproximadamente un 2,18% de transacciones fraudulentas. Debido a esta característica, se aplicaron técnicas específicas para el tratamiento del desbalance y la detección de anomalías.

En la fase exploratoria se utilizaron técnicas de reducción de dimensionalidad mediante PCA y detección de anomalías con DBSCAN. Posteriormente se entrenaron modelos supervisados de Regresión Logística y Random Forest para la clasificación de fraudes.

Los resultados mostraron que Random Forest obtuvo el mejor desempeño global, alcanzando un Accuracy de 97.6%, un AUC-ROC de 0,988 y un F1-Score de 0,54. Además, el análisis de importancia de variables reveló que la información derivada del agrupamiento mediante DBSCAN fue el predictor más relevante para identificar transacciones fraudulentas.

---

2. Datos y metodología

Descripción de los datos

El conjunto de datos contiene información relacionada con:

- Características demográficas de los clientes.
- Antigüedad de las cuentas.
- Monto de las transacciones.
- Canales utilizados para realizar operaciones.

- Ubicación geográfica.
- Estado de las transacciones.
- Etiqueta de fraude (es_fraude).

Distribución de la variable objetivo

Clase	Proporción
No fraude	97,82%
Fraude	2,18%

La baja frecuencia de fraudes justificó la utilización de modelos balanceados mediante class_weight='balanced'.

Preprocesamiento

Se realizaron las siguientes etapas:

- Corrección de formatos de datos.
- Tratamiento de valores faltantes.
- Verificacion y eliminación de duplicados.
- Codificación de variables categóricas mediante One-Hot Encoding (get_dummies).
- Escalado de variables numéricas.
- Creación de nuevas variables mediante ingeniería de características.
- Transformación logarítmica del monto (monto_log).

Análisis exploratorio

PCA

Se aplicó PCA para reducir la dimensionalidad y facilitar la visualización de patrones.

Varianza explicada

Componentes	Varianza acumulada
2 componentes	44,19%

3 componentes	55,72%

DBSCAN

Se aplicó DBSCAN para detectar observaciones anómalas.

Parámetros utilizados:

- eps = 0.8
- min_samples = 10

Resultados:

Indicador	**Valor**
Anomalías detectadas	558
Porcentaje de anomalías	11,16%
Fraude dentro de anomalías	19,53%
Fraude general	2,18%

Las anomalías identificadas presentaron una tasa de fraude aproximadamente nueve veces superior a la observada en la población general.

Modelado supervisado

Se realizó una división estratificada:

- Entrenamiento: 80% (4.000 registros)
- Prueba: 20% (1.000 registros)

Se entrenaron dos modelos:

1. Regresión Logística
2. Random Forest

---

3. Resultados cuantitativos

Regresión Logística

Matriz de confusión

Regresion logistica

Métrica	Original	80/20	Variación
Accuracy	93.8%	94.6%	↑ 0.8 pp
ROC-AUC	0.975	0.983	↑ 0.008
Precision	0.25	0.28	↑ 0.03
Recall	0.94	0.95	↑ 0.01
F1-score	0.40	0.44	↑ 0.04
Fraudes detectados	31	21	-
Fraudes perdidos	2	1	Mejora
Falsas alarmas	91	53	Mejora

Random Forest

Métrica	Original	80/20	Variación
Accuracy	98.1%	97.6%	↓ 0.5 pp
ROC-AUC	0.987	0.988	↑ 0.001
Precisión	0.54	0.47	↓ 0.07
Recall	0.76	0.64	↓ 0.12
F1-score	0.63	0.54	↓ 0.09
Fraudes detectados	25	14	-
Fraudes perdidos	8	8	Sin cambio
Falsas alarmas	21	16	Mejora

Random Forest obtuvo el mejor desempeño global, mientras que Regresión Logística destacó por maximizar la detección de fraudes.

---

4. Visualizaciones clave

Las principales visualizaciones utilizadas durante el análisis fueron:

1. Heatmap de valores nulos

Permitió verificar la calidad de los datos y confirmar que el conjunto estaba adecuadamente preparado para el modelado.

2. PCA bidimensional y tridimensional

Se utilizaron para explorar la distribución de las observaciones y visualizar posibles agrupamientos.

3. Visualización de DBSCAN en espacio PCA

La proyección PCA permitió observar la ubicación de los registros identificados como anomalías (cluster = -1) y su relación con los casos de fraude.

4. Matrices de confusión

Se construyeron mediante sns.heatmap() para comparar visualmente el desempeño de ambos modelos supervisados.

5. Curvas ROC

Las curvas ROC superpuestas mostraron que ambos modelos poseen alta capacidad discriminativa, aunque Random Forest presentó la curva más cercana a la esquina superior izquierda y el mayor valor de AUC.

6. Importancia de variables

El gráfico de importancia de variables permitió identificar las características con mayor contribución al modelo Random Forest.

---

5. Interpretación y recomendaciones

Variables más importantes

Variable	Importancia
dbscan_cluster	0,401
monto	0,158
monto_log	0,154
cat__nivel_monto_Muy_Alto	0.065330
antiguedad_cuenta_meses	0.039962

La variable más importante fue **dbscan_cluster**, representando aproximadamente el 50% de la importancia total del modelo.

Este resultado demuestra que la información generada mediante técnicas no supervisadas aporta un valor significativo para la detección de fraude.

Asimismo, el monto de las transacciones y su transformación logarítmica mostraron una relevancia elevada, indicando que el valor económico constituye uno de los principales factores asociados a comportamientos fraudulentos.

Recomendaciones

1. Implementar Random Forest como modelo principal de detección de fraude.

2. Mantener DBSCAN como mecanismo complementario para identificar comportamientos atípicos.
3. Priorizar la revisión manual de las transacciones clasificadas simultáneamente como fraude y anomalía.
4. Incorporar nuevas variables temporales y de comportamiento transaccional para mejorar la capacidad predictiva.
5. Realizar recalibraciones periódicas del modelo para adaptarse a cambios en los patrones de fraude.

---

6. Limitaciones y próximos pasos

Realizar una selección de variables más adecuada (mantener solo log monto, decidir si dejar o quitar las categorías creadas para el análisis...)

Incluir más componentes en el PCA para explicar una mayor varianza del modelo

Evaluar los modelos con diferentes porcentajes de train y test

Conclusión general

Los resultados obtenidos evidencian que la combinación de técnicas de análisis exploratorio, detección de anomalías y aprendizaje supervisado constituye una estrategia efectiva para la detección de fraude financiero. Entre los modelos evaluados, **Random Forest** presentó el mejor equilibrio entre precisión, capacidad discriminativa y reducción de falsas alarmas, convirtiéndose en la alternativa más adecuada para una posible implementación operativa.